

多変量解析 及び大規模計算論 第4回

玉森, 内種

今日の内容

ロジスティック回帰

主成分分析(少し)

ロジスティック回帰

ロジスティック回帰とは？

これまでの回帰分析

⇒ 目的変数が連続値

ロジスティック回帰分析

⇒ 目的変数が離散値（カテゴリ値）

※カテゴリ値: 0 or 1 の2値 や 0, 1, 2, ... の多値

⇒ 簡単のために2値の場合を考えることにする

定式化

目的変数が2種類の値しかとらない2値データ

- 製品の品質が良品か不良品で示される場合
- あるアンケート調査で、意見に賛成か反対かで示される場合

定式化

2種類の事象のうち、一方が起きる確率を p とする

⇒不良品の例でいうと、不良品の発生する確率が p


p を予測するための説明変数を x とするとき、

p と説明変数の関係を数式で表現することが


ロジスティック回帰の目的

ロジスティック回帰のころ

目的変数が0/1からなる2値データ



そのまま線形回帰を行ってしまうと、予測値が0~1の範囲を超えてしまう



目的変数をロジット変換し、
回帰を行う



予測値が0~1の範囲に収まる

確率表現

定式化

確率 p と説明変数 x の間に, 次のような関係を想定する


※ 説明変数は複数でもOKですが, 今は簡単のため1つだけ

$$p = \frac{1}{1 + e^{\{-(b_0 + b_1 x)\}}} = \frac{1}{1 + \exp \{-(b_0 + b_1 x)\}}$$

ロジスティック回帰に現れる謎の関数

実はシグモイド関数

$$\frac{1}{1 + e^{-x}}$$



対数オッズとロジット変換

p の式を少し変形すると、以下の回帰式を求めることと同じ

$$\ln \left(\frac{p}{1-p} \right) = b_0 + b_1 x$$

$\frac{p}{1-p}$: オッズ

$\ln \left(\frac{p}{1-p} \right)$ p に対する
ロジット変換
 $\Rightarrow$ 対数オッズ

ロジスティック回帰のこころ

確率 p は $0 \leq p \leq 1$ に制限されている

logit を取ると値の範囲が $(-\infty, \infty)$ になる:

$p \rightarrow 0$ なら $-\infty$

$p = 0.5$ なら 0

$p \rightarrow 1$ なら ∞

$$\ln \left(\frac{p}{1-p} \right)$$

⇒ **線形回帰** で扱いやすい(値の範囲)！

ロジスティック回帰の学習

尤度の最大化(最尤推定)によりパラメータを求める

入力 $\mathbf{x}_i$ (多変数を考慮したベクトル)に対して以下を仮定:

$$P(y_i = 1 \mid \mathbf{x}_i) = \sigma(\mathbf{w}^\top \mathbf{x}_i + b)$$

$\mathbf{w}$ は重みベクトル、 σ はロジスティック関数:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

ロジスティック回帰の学習

各データ $(\mathbf{x}_i, y_i)$

に対して $y_i \in \{0, 1\}$ とすると条件付き確率は

$$P(y_i \mid \mathbf{x}_i) = p_i^{y_i} (1 - p_i)^{1-y_i}$$

ただし

$$p_i = \sigma(\mathbf{w}^\top \mathbf{x}_i + b)$$

ロジスティック回帰の学習

独立同分布を仮定すると、データ全体に対する尤度関数は

$$L(\mathbf{w}, b) = \prod_{i=1}^N p_i^{y_i} (1 - p_i)^{1-y_i}$$

実際によく使うのは**対数尤度**：

$$\ell(\mathbf{w}, b) = \log L(\mathbf{w}, b) = \sum_{i=1}^N [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$$

ロジスティック回帰の学習

実際のパラメタの学習では負の対数尤度を使い、これを最小化：

$$\begin{aligned} J(\mathbf{w}, b) &= -\ell(\mathbf{w}, b) \\ &= -\sum_{i=1}^N [y_i \log p_i + (1 - y_i) \log(1 - p_i)] \end{aligned}$$

⇒どうやって最小化するのか？

⇒勾配降下法

勾配降下法

お気持ち: J が小さくなる方向に、パラメタを少しずつ動かす

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \frac{\partial J}{\partial \mathbf{w}} \qquad b \leftarrow b - \eta \sum_{i=1}^N (p_i - y_i)$$

ただし

$$\frac{\partial J}{\partial \mathbf{w}} = \sum_{i=1}^N (p_i - y_i) \mathbf{x}_i \qquad \frac{\partial J}{\partial b} = \sum_{i=1}^N (p_i - y_i)$$

おまけ: 勾配の導出

$$J(\mathbf{w}, b) = - \sum_{i=1}^N [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$$

ただし

$$p_i = \sigma(z_i), \quad z_i = \mathbf{w}^\top \mathbf{x}_i + b$$

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

おまけ:勾配の導出

Jを z_i で偏微分する:

$$J(\mathbf{w}, b) = - \sum_{i=1}^N [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$$

$$\begin{aligned} \frac{\partial J}{\partial z_i} &= - \left[y_i \frac{1}{p_i} \frac{\partial p_i}{\partial z_i} + (1 - y_i) \frac{1}{1 - p_i} \frac{\partial(1 - p_i)}{\partial z_i} \right] \\ &= - \left[y_i \frac{1}{p_i} \frac{\partial p_i}{\partial z_i} - (1 - y_i) \frac{1}{1 - p_i} \frac{\partial p_i}{\partial z_i} \right] \\ &= - \frac{\partial p_i}{\partial z_i} \left[\frac{y_i}{p_i} - \frac{1 - y_i}{1 - p_i} \right] \quad \text{ただし} \quad \frac{\partial p_i}{\partial z_i} = p_i(1 - p_i) \end{aligned}$$

おまけ:勾配の導出

シグモイド関数の微分を代入して次式を得る:

$$\frac{\partial J}{\partial z_i} = -p_i(1 - p_i) \left[\frac{y_i}{p_i} - \frac{1 - y_i}{1 - p_i} \right]$$

さらに展開して整理すると:

$$\begin{aligned} \frac{\partial J}{\partial z_i} &= -[y_i(1 - p_i) - (1 - y_i)p_i] \\ &= -(y_i - p_i) \end{aligned}$$

おまけ: 勾配の導出

次は連鎖律を用いる。

$$z_i = \mathbf{w}^\top \mathbf{x}_i + b \quad \text{より}$$

$$\frac{\partial z_i}{\partial \mathbf{w}} = \mathbf{x}_i$$

ゆえに

$$\begin{aligned} \frac{\partial J}{\partial \mathbf{w}} &= \sum_{i=1}^N \frac{\partial J}{\partial z_i} \frac{\partial z_i}{\partial \mathbf{w}} \\ &= \sum_{i=1}^N (p_i - y_i) \mathbf{x}_i \end{aligned}$$

$$\frac{\partial J}{\partial \mathbf{w}} = \sum_{i=1}^N (p_i - y_i) \mathbf{x}_i$$

導出完了！

おまけ:勾配の導出

b に関する勾配も、方針は同様。

$$z_i = \mathbf{w}^\top \mathbf{x}_i + b \quad \text{より}$$

$$\frac{\partial z_i}{\partial b} = 1$$

ゆえに

$$\begin{aligned} \frac{\partial J}{\partial b} &= \sum_{i=1}^N \frac{\partial J}{\partial z_i} \frac{\partial z_i}{\partial b} \\ &= \sum_{i=1}^N (p_i - y_i) \end{aligned}$$

$$\frac{\partial J}{\partial b} = \sum_{i=1}^N (p_i - y_i)$$

導出完了！

実はニューラルネットワークとも見なせる

ロジスティック回帰は2層のニューラルネットワーク

* 入力層と出力層からなる2層

ただし活性化関数がシグモイド関数(非線形関数)

単回帰, 重回帰も2層ニューラルネットワーク

ただし活性化関数が恒等関数(線形関数)

ロジスティック回帰の利点

- シンプルなモデル

- 理解しやすく、実装しやすい

- 少ないデータで学習できる

- モデルのシンプルさ、損失関数の凸性

- 確率解釈が可能

- データ点が特定のカテゴリに属する確率を予測できる

ロジスティック回帰の制約

決定境界が線形であることが必要

→ 決定境界は $P(y = 1 \mid \mathbf{x}) = 0.5$ になるようなところ

$$\text{つまり } \mathbf{w}^\top \mathbf{x} + b = 0$$

→ 1次元なら直線、2次元なら平面、高次元なら超平面

∴ 「線形な境界でしか分類できない」というわけ

非線形な境界で分類したいなら、多項式特徴とかカーネル法、

もしくは多層ニューラルネットを用いる

例題

prob_6-3.csvはあるプラスチック加工品の完成時における品質と, 製造工程における熱処理時間(単位: 秒)について記録したものである. 品質については, 良品を0, 不良品を1としている.

熱処理時間x	品質y
25.5	0
40.7	0
10.2	0
17.2	0
40.9	1
46.8	1
39.6	1
32.3	1

※この表は抜粋したもの

例題(つづき)

不良品の発生する確率を p , 説明変数を x として, 次のような関係を想定する.

$$p = \frac{1}{1 + e\{-(b_0 + b_1 x)\}}$$

データにロジスティック回帰を適用して b_0 と b_1 の値を求めよ.

熱処理時間 x	品質 y
25.5	0
40.7	0
10.2	0
17.2	0
40.9	1
46.8	1
39.6	1
32.3	1

※この表は抜粋したもの

演習

演習1

prob_6-5.csvのデータに対して、x1, x2, x3, x4の中の一つだけ説明変数にとりあげて、yを目的変数とするロジスティック回帰分析を説明変数ごとに実施せよ。

x1	x2	x3	x4	y
14	98	52	61	0
42	104	51	69	0
17	98	51	67	0
27	104	63	77	0
19	99	60	61	0
53	113	76	83	1
21	108	65	90	1
33	104	82	80	1
42	104	78	76	1
49	107	82	77	1

※この表は抜粋したもの

演習1(つづき)

prob_6-5.csvのデータに対して、x1, x2, x3, x4の全てを説明変数にとりあげて、yを目的変数とするロジスティック回帰分析を実施せよ.

x1	x2	x3	x4	y
14	98	52	61	0
42	104	51	69	0
17	98	51	67	0
27	104	63	77	0
19	99	60	61	0
53	113	76	83	1
21	108	65	90	1
33	104	82	80	1
42	104	78	76	1
49	107	82	77	1

※この表は抜粋したもの

主成分分析

主成分分析とは？

多変数のデータから**主成分**と呼ばれる少数の新たな変数を合成し、次元の圧縮を行う情報要約手法

主成分分析のご利益

通常、多変数のデータに対して散布図などによる**視覚化**を行うのは2変数もしくは3変数が限界

※何のための視覚化か？

→変数間の関係性を解釈するのに役立つ

⇒高次元データの視覚化(解釈)はちょっと難しい

主成分分析のご利益

通常、多変数のデータに対して散布図などによる**視覚化**を行うのは2変数もしくは3変数が限界

※何のための視覚化か？

→変数間の関係性を解釈するのに役立つ

⇒主成分分析により合成した主成分(**低次元表現**)を用い、サンプルを分類したり特徴づけしたりすることが可能

⇒**解釈性の向上**，新たな関係性の発見

例題

例題

右の表は生徒10人の試験に関する点数である

この5科目の試験に関する
得点を主成分分析せよ

No	国語	社会	数学	理科	英語
1	58	49	58	74	57
2	47	42	50	59	45
3	47	39	54	69	49
4	53	47	65	79	57
5	52	53	48	65	56
6	43	35	44	60	43
7	48	42	47	65	51
8	54	49	64	80	49
9	44	40	55	70	43
10	39	37	55	65	47

考え方

観測データの数が10

特徴量次元が5

と考える

→5次元ベクトルが10本

No	国語	社会	数学	理科	英語
1	58	49	58	74	57
2	47	42	50	59	45
3	47	39	54	69	49
4	53	47	65	79	57
5	52	53	48	65	56
6	43	35	44	60	43
7	48	42	47	65	51
8	54	49	64	80	49
9	44	40	55	70	43
10	39	37	55	65	47


Google Colab

主成分分析(例題).ipynb

結果


主成分分析のバイプロット

⇒どの変数どうしの関連が強いかわかる、どの生徒どうしが似た特徴を持っているかを視覚的に把握できる



結果

累積寄与率



そのほか、主成分分析のご利益(私見)

次元削減することで、

機械学習アルゴリズムの計算量削減にもつながる

そのほか、「次元の呪い」※ を回避できる(かもしれない)

※ 機械学習アルゴリズムが高次元データに対して期待通りに動作しない現象全般を指すことば

演習

演習2

prob_5-1.csvはある大学における入学前教育の5科目（国語，英語，数学，理科，社会）の試験の点数と，入学後の学業成績を示すGPAと呼ばれる指標である．学生25人について記録されている．5科目の試験の点数で，GPAの値を予測する回帰式を作りたい．

このデータ表に対して，目的変数をGPA，説明変数を5科目の試験の点数とする重回帰分析を実施せよ．

演習3

表データ(prob_5-2.csv)は体育のデータである.

項目は以下の通り:


- 反復横飛び(hjump)
- 垂直跳び(vjump)
- 背筋力(back)
- 握力(grip)
- 50m走(50mrun)
- 走り幅跳び(ljump)

演習3

表データ(prob_5-2.csv)は体育のデータである.

(1)このデータに対して, 相関係数行列から出発する主成分分析を行い, 固有値(新しい座標軸方向の分散の大きさ), 因子付加量(因子付加行列 / 固有ベクトル), および主成分得点(新しい座標軸の成分)を求めよ. また, 因子付加量と主成分得点のバイプロットを求めよ. 累積寄与率も求めよ.

実行例(バイプロット)



実行例(累積寄与率)

