

多変量解析 及び大規模計算論 第5回

玉森, 内種

今日の内容

主成分分析(資料的な続き)

因子分析

クラスター分析

主成分分析の演習

演習1

prob_5-1.csvはある大学における入学前教育の5科目（国語，英語，数学，理科，社会）の試験の点数と，入学後の学業成績を示すGPAと呼ばれる指標である．学生25人について記録されている．5科目の試験の点数で，GPAの値を予測する回帰式を作りたい．

このデータ表に対して，目的変数をGPA，説明変数を5科目の試験の点数とする重回帰分析を実施せよ．

演習2

表データ(prob_5-2.csv)は体育のデータである.

項目は以下の通り:

- 反復横飛び(hjump)
- 垂直跳び(vjump)
- 背筋力(back)
- 握力(grip)
- 50m走(50mrun)
- 走り幅跳び(ljump)

演習2

表データ(prob_5-2.csv)は体育のデータである.

(1)このデータに対して, 相関係数行列から出発する主成分分析を行い, 固有値(新しい座標軸方向の分散の大きさ), 因子付加量(因子付加行列 / 固有ベクトル), および主成分得点(新しい座標軸の成分)を求めよ. また, 因子付加量と主成分得点のバイプロットを求めよ. 累積寄与率も求めよ.

因子分析

因子分析とは？

観測変数の背後に潜む**潜在因子**を想定し、

その潜在因子から観測変数が合成されたと考える

観測変数が合成される際に、誤差による変動も加わる

主成分分析は多変数のデータから、

主成分と呼ばれる少数の新たな変数を合成して**次元の圧縮**を図る

⇒因子分析と主成分分析は**因果関係が逆**

例示

データの背後にある共通因子



理系力



文系力

	生徒1	生徒2	生徒3	生徒4
国語	85	50	80	95
算数	45	100	95	60
理科	40	90	90	65
社会	75	60	75	80
英語	90	65	70	100

<https://qiita.com/roki18d/items/b76b8d153111814d84d4>


因子分析とは？

因子分析はデータ生成モデル

主成分分析はデータ生成モデルではない

⇒「向きが逆」

図示




共通因子数を2とした場合の5科目データの生成モデル

例題

x_i ($i = 1, 2, \dots, 5$)は観測変数

f_1, f_2 は共通因子



a_{ij} は観測変数が共通因子から受ける重み

⇒因子負荷量

ε_i は独自因子(誤差)

演習3

prob_3-2.csvのデータに対して、因子分析を行え。ただし因子数は2とする。

寄与率，因子負荷量，因子得点，およびバイプロットを求めよ。
結果を観察し，考察も付記せよ。

演習4

prob_5-2.csvのデータに対して、因子分析を行え。ただし因子数は3とする。

寄与率，因子負荷量，因子得点，およびバイプロットを求めよ。
結果を観察し，考察も付記せよ。

クラスター分析

クラスター分析とは？

サンプル間の**距離**を定義して、距離の近さでサンプルを分類する方法.

- 階層的クラスタリング
- 非階層的クラスタリング

クラスター分析の応用例

- ショッピングサイトの購買履歴から顧客をグループ分けする
- ウェブサイトの閲覧履歴や検索履歴に基づいて、ユーザをグループ分けする
- レビューから、製品に対する意見をグループ分けする
- 心理学のアンケート調査から人間を類型化する
- 遺伝子の発現データから似ている遺伝子群を見つける、もしくは似ている個体群を見つける

階層的クラスタリング

Notebookを参照

長所: デンドログラムが描けること

⇒ 非階層的クラスタリングではデンドログラムは描けない

短所: 計算に時間がかかる

⇒ すべての点どうしの距離を計算しなければならない

※ 計算オーダはどれくらい？

階層的クラスタリング

短所: 変数についての情報が読み取りづらい

⇒ ヒートマップによる可視化

クラスター間距離の計算方法(1/3)

最近隣法: 2つのクラスタ間の距離を、2つのクラスタ間にあるデータポイント間の最小距離で計算

- メリット: 計算が簡単
- デメリット: 外れ値の影響を受けやすい、デンドログラムが長くなる傾向がある

最遠隣法: 2つのクラスタ間の距離を、2つのクラスタ間にあるデータポイント間の最大距離で計算

- メリット: 外れ値の影響を受けにくい
- デメリット: 計算が複雑、密なクラスタを見つけにくい

クラスター間距離の計算方法(2/3)

平均間距離法 : 2つのクラスタ間の距離を、2つのクラスタ間にあるすべてのデータポイント間の距離の平均値で計算

- メリット : 最近隣法と最遠隣法の中間の性質を持つ
- デメリット : 計算が複雑

重心法 : 各クラスタの重心を計算し、その重心間の距離をクラスター間距離として計算

- メリット : 球状のクラスタを見つけやすい
- デメリット : 非球状のクラスタを見つけにくい

クラスター間距離の計算方法(3/3)

ワード法 : 2つのクラスタを結合する際に、**結合後のクラスタの分散が最小になるように** データポイントを結合

- メリット : 球状のクラスタを見つけやすい
- デメリット : 非球状のクラスタを見つけにくい、計算が複雑

メディアン法 : 2つのクラスタ間の距離を、2つのクラスタ間にあるすべてのデータポイント間の距離の中央値で計算

- メリット : 外れ値の影響を受けにくい、ワード法よりも計算が速い
- デメリット : 球状のクラスタを見つけにくい

非階層的クラスタリング

データを指定した数のクラスタに分ける手法.

長所: 計算に時間がかからない(階層的のそれと比較して)

短所: クラスタ数を先に指定する必要, デンドログラムも不可

k-means法

代表的な手法

notebookで具体例を見る

k-means法の数理

notebook 参照

その他のクラスタリング手法

<https://scikit-learn.org/stable/modules/clustering.html>

クラスター分析の演習

演習5

prob_7-1.csvは動物のデータである.

階層的クラスタリングを行い, どの動物が似ていて, どの動物が似ていないかをデンドログラムにより視覚化せよ.

演習6

prob_7-2.csvは自動車のデータである.

クラスタ数を3として, k-means法による非階層的クラスタリングを行い, 各クラスタのサンプル数を集計せよ.

演習7

prob_7-2.csvは自動車のデータである.

階層的クラスタリングを行い, デンドログラムを作成せよ.

演習 8

教育用標準データセット (SSDSE) (<https://www.nstac.go.jp/SSDSE/>)
に収録されている

都道府県庁所在市別・家計消費データ (SSDSE-C) に対してクラスタ分析を適用し、消費行動が類似している都道府県のクラスタを作りたい。

演習 8

(1) このデータセットを読み込み、各都道府県庁所在地を特徴ベクトルで表現せよ。

(2) K-meansクラスタリングを異なるクラスタ数 K で実行し、横軸にクラスタ数、縦軸に K-means の目的関数の値、すなわちクラスタ内平方和 (WCSS: within-cluster sum-of-squares) をプロットしたグラフを描画せよ。

(3) (2) の結果に基づき、クラスタ数 K を適当に選び、K-meansクラスタリングを実行せよ。1 から K までの各クラスタに対して、それぞれ所属する都道府県庁所在地を明らかにせよ。